데이터 활용 명세

「제주 AI·빅데이터 활용 AI Agent 개발 챌린지」 제출작 **오름(OREUM)**

필수 데이터 조건: 제주빅데이터센터 또는 제주데이터허브 데이터 1종 이상 → **제주데이터허브 실데이터 8종(공개 파일 5종 + Open API 3종)을 내장·호출**하고, **센터 데이터 9종(구버전 v01 4종 호환, 총 13종 인식)**을 넣으면 최신·세부 분석으로 확장. **가상 데이터는 쓰지 않음**(테스트용 형식 검증 데이터만 별도).

---

1. 제주빅데이터센터 제공데이터 (명세서 v13, 2026.11.04 기준)

센터 PC에서 이용자가 센터 조회 화면으로 **1개월 단위 CSV**를 내려받아 오름에 넣는 방식(게시판 공식 답변 준수). Agent는 센터 DB에 직접 연결하지 않음.

ID	데이터명	반출 등급	활용 분석	활용 항목(컬럼)
1-08	카드 이용 현황 (읍면동)_v02	불가(가공 시 가능)	①상권 ②축제	base_year_month, dstrct_se, bjd, biz_cd, biz_nm, user_type, tour_type, age, sex, user_cnt, use_cnt, use_amt
1-07	카드 이용 현황 (읍면동)_v01	불가	①② (과거 기간)	위와 동일(dstrct_se 없음)
1-12	카드 이용 현황 (요일별)_v02	불가	①상권	bjd, biz_cd, week, use_cnt, use_amt
1-14	카드 이용 현황 (시간대)_v02	불가	①상권	bjd, biz_cd, time, use_cnt, use_amt
1-11·1-13	요일별·시간대 v01	불가	① (과거 기간)	위와 동일
4-11	내국인 유동인구 (읍면동)_v02	불가	①상권 ②축제	base_date, time, emd_nm, sex, age, resd/work/visit_pop_cnt
4-10	내국인 유동인구 (읍면동)_v01	불가	①② (2025.04 이전)	위와 동일(dstrct_se 없음)
3-03	버스 정류소 정보	가능	①②③	bus_station_id, bus_station_name, longitude, latitude
3-04	버스 정류소별 이용 현황	가능	①②③	base_date, base_hour, bus_station_id, get_on_off_type, user_category, user_count
3-02	버스 노선별 이용 현황	가능	③버스	base_date, base_hour, bus_route_name, user_count
5-02	일일 날씨 정보	가능	②축제	base_date, average_temperature, daily_rainfall, average_wind_speed
1-17	제주도 내 업종별 매장 수	불가	(참고)	city, biz_cd, store_cnt

- 이용조건: 센터 내 분석, 결과는 「제주빅데이터센터 데이터 반출 정책(2026.09.01)」에 따라 가공 형태로만 반출. 출처 표기 「제주빅데이터센터, 데이터셋(이름, 기간)」— 오름이 보고서·반출 신청서 초안에 자동 기재.

- 데이터 명세서(엑셀)는 외부 공개 자료로 제출물에 포함(`app/catalog/spec_catalog.json` 으로 구조화, 원본 미포함 시 `tools/build_catalog.py` 로 재생성).

2. 제주데이터허브 공개 데이터 (번들, `data/public/`)

허브에서 내려받은 **공개 원본 데이터**를 전처리해 포함(게시판 공식 답변: 공개 원본·전처리본 제출물 포함 가능, 출처·전처리 명시).

허브 ID	데이터명	원출처	활용	전처리
793	제주특별자치도 상가(상권) 정보	공공데이터포털 (소상공인시장진흥공단), 2025.09	①경쟁 점포 수·위치, 법정동 중심좌표	필요 컬럼 선택(상호·업종 대/중/소·표준산업분류·행정동·법정동·좌표), parquet 변환
761	제주관광공사 VISIT JEJU 축제행사콘텐츠	제주관광공사(공공데이터포털 경유)	②행사명·기간 검색	날짜 파싱, 종료<시작 등 오류 행 제거, 중복 제거
746	예비창업자를 위한 업종별 카드 매출과 매장수 매쉬업	제주특별자치도(센터 데이터 활용)	①장기 추세·센터 데이터 없을 때 대체	월×읍면동×업종(×이용자구분) 합계로 집계
748	상권분석을 위한 유동인구에 따른 카드 매출액 변화 매쉬업	제주특별자치도	①유동인구-매출 관계 참고	월×읍면동×업종 집계
512	일별 시간대별 버스 승차 인원 수 현황	제주빅데이터센터	③제주 전역 진단(월별 추이·요일×시간대·이용자 유형)	원본 그대로(일×시간대×이용자 유형), 일 합계가 중앙값 30% 미만인 날은 분석 시 결측 처리

- 출처 URL: `https://jejudatahub.net/data/view/data/<ID>` (상세: `data/public/PROVENANCE.json`)
- 이용조건: 「공공데이터의 제공 및 이용 활성화에 관한 법률」 및 허브 이용약관에 따름(게시판 답변).
- 대회 제공 「제주데이터허브 데이터 목록 xlsx」는 제3자 배포 금지 자료이므로 **제출물·코드에 포함하지 않음**.

제주데이터허브 Open API (스냅샷 내장 + 키가 있으면 Agent가 직접 호출)

허브 ID	API	활용	내장 스냅샷(`data/public/`)
583	읍면동 단위 내국인 유동인구(일별·성·연령)	①최근 2년 방문인구 추이·연령 ②행사 전후 일별 방문인구·이중차분	`pop583_daily.parquet` — 대정읍·안덕면·한경면 2024.11.07~12.08, 대정읍 2023.11.09~12.10, 애월읍 2023.10.21~2025.10.20
612	버스 정류소 기본 정보	②③정류소 좌표	`stops612.parquet` — 전체 4,352곳(2026.11 조회)
613	일일 정류소별 버스 이용자 정보	②행사장 인근 승차 ③정류소 순위·저이용 정류소	`stop_usage613.parquet` — 2024.11.14~17·21~24·28~12.01(행사일 + 같은 요일 기준선 2주, 전 정류소)

- 호출 주소: `https://open.jejudatahub.net/api/proxy/{dataKey}/{프로젝트키}` (키는 `.env` 의 `JEJU_HUB_PROJECT_KEY` , 제출물 미포함)
- 키가 있으면: 질문한 지역·기간이 스냅샷에 없을 때 Agent가 583을 직접 조회(읍면동 필터, 100건/쪽 페이지 처리, 디스크 캐시, 데이터별 일일 1,000회 쿼터 보호). 호출 내역은 화면 진행 기록에 표시.

- 키가 없으면: 스냅샷으로 대표 시나리오를 그대로 재현. 스냅샷 재생성은 `tools/fetch_hub_api.py`.
- 613(카드 단말 정류소 ID)과 612(BIS 정류소 ID)는 ID 체계가 달라 **정류소 이름(공백·가운뎃점 제거)으로 연결**, 같은 이름의 양방향 정류소는 합산·좌표 평균. 연결률은 승차 기준 약 97%.
- 583은 일 단위 값(성·연령별)으로, 분석은 같은 요일 기준선·이중차분처럼 **상대 비교**에 사용(절대 인원 해석 지양).

3. 수집·전처리·분석 흐름

```
[센터 조회 화면] 1개월 CSV ──▶ ① 자동 인식(헤더 ↔ 명세서 71종 대조, v01/v02 구분, 선택 컬럼만 있어도 인식)
                                ② 병합(여러 달) · 중복 제거 · 결측(NA) 처리 · 숫자형 변환 · 빠진 기간 탐지
[허브 실데이터(내장)·Open API] ▶ ③ 지역·업종 사전으로 표준화(법정동↔행정동↔7권역, BC 42업종↔상가 업종, 정류소 이름 연결)
                                ④ 로컬 분석(결정적 계산: 추세·요일/시간 지수·고객 구성·경쟁·유동인구·이중차분·첨두 집중도)
                                ⑤ 반출 검사(10 미만 범주처리/삭제처리 + 역산 방지 보완 억제, 기반 건수 규칙)
                                ⑥ 차트(PNG)·LLM 해석(검사 통과 집계표만)·수치 근거 검증
                                ⑦ 보고서(PDF·DOCX) + 반출 신청서 초안(자료별 출처·가공 방식·활용 사유)
```

- 원본 행은 화면·보고서·LLM 어디에도 출력하지 않음(반출 정책: `data.head()` 출력 결과 포함 시 반출 불가).
- 업로드 CSV·결과는 세션 폴더에만 저장, 퇴실 정리 시 삭제.

계획 단계의 데이터 탐색

분석 실행 전 계획 단계에서 Agent가 `search_datasets`와 `get_dataset` 도구로 명세서 카탈로그를 검색해 데이터를 고르고, 고른 이유를 화면과 체크리스트에 표시합니다. - **카탈로그 원천**: 제주빅데이터센터 데이터 명세서(`spec_catalog.json`, `tools/build_catalog.py` 생성), 제주데이터허브 공개 데이터 목록 중 오름이 내장한 데이터. - 계획 Agent는 데이터 값(원본 행·집계값)은 보지 않고 공개 명세 요약(ID·이름·기간·갱신 주기·반출 등급·설명)만 조회하여 분석에 적합한 데이터셋을 선정합니다.

4. 테스트용 형식 검증 데이터 (화면·보고서에서는 쓰지 않음)

- 시연·결과물은 모두 위 **실데이터**로 만든다. 화면의 '가상 데이터 불러오기' 기능과 설치 시 가상 데이터 생성 단계는 제거했다.
- 다만 센터 CSV 인식·병합·반출 검사 같은 **센터 데이터 경로**는 센터 밖에서 실데이터로 시험할 수 없으므로, 명세서 v13 형식을 따른 테스트 전용 데이터를 `tools/make_demo_data.py`로 만들어 자동 테스트(`tests/`)에서만 사용한다(고정 시드, 파일명 `SYNTHETIC_` 표시).
- 업로드된 파일이 이 형식 검증 데이터이면 화면·보고서에 '가상' 경고가 자동으로 붙는다.

5. 지역·업종·축제 사전 (`app/catalog/`)

사전	내용	근거
`spec_catalog.json`	명세서 71종 데이터셋(74시트 중 목록·참고표 제외)의 컬럼·형식·반출 등급·측정값/차원·버전 관계	데이터 명세서 v13

사전	내용	근거
`region_data.json`	법정동 73개(월평동 2곳 구분, 74행)·행정동 43개·리(里) 122곳, 법정동↔행정동 대응(점포 수 다수결·비율), 중심좌표	명세서 + 허브 상가정보 점포 좌표
7개 권역 대응	행정동→권역 **추정**(신뢰도 표시), CSV의 `dstrct_se` 값이 있으면 실측값 우선	명세서·게시판 답변(노형동·대정읍·월평동 확정)
업종 사전	BC 42업종 ↔ 자연어 별칭(카페·횟집·숙소 등) ↔ 상가정보 업종(점포별 BC 업종 코드 부여)	명세서 참고표 + 허브 상가정보
축제 장소	허브 축제 목록 522건(정제 후 507건) + **주요 축제 49곳 장소·좌표 큐레이션**(신뢰도 high/medium/low)	허브 761 + 공개 정보

6. 외부 데이터·오픈소스·AI 목록

구분	이름	라이선스/조건	용도
AI 모델	OpenAI `gpt-6-luna` (추론 high) 기본, Anthropic Claude 선택	상용 API(센터 발급 키)	계획(도구 선택·데이터 선택)·질문 해석·결과 해석·후속 답변
지도 타일	OpenStreetMap	ODbL, 화면 표시 시 저작자 표기	화면 지도 배경
JS	Leaflet 1.9.4	BSD-2-Clause	화면 지도
글꼴	Pretendard 1.3.9(가변)	SIL Open Font License 1.1	화면 글꼴(오프라인 동봉, 라이선스 `web/vendor/fonts/Pretendard_LICENSE.txt`)
화면 배경	제주 해안·돌하르방 사진(Pixabay 7910450 "ocean-statue-rocks-coast") + 파도 영상화(Wan2.2-TI2V-5B)	Pixabay Content License(무료, 출처 표기 의무 없음) · Apache-2.0	화면 배경 영상·사진(`web/vendor/bg/CREDITS.txt`)
Python	FastAPI, Uvicorn, pandas, NumPy, PyArrow, Matplotlib, Jinja2, python-docx, python-dotenv, openai, anthropic	MIT/BSD/Apache-2.0/PSF	서버·분석·차트·보고서
공휴일	관공서 공휴일(2023~2026)	공공 정보	요일별 하루 평균 지수 계산
개발 도구	Claude Code	—	코드·문서 작성 보조